

第7+章(*) 机器学习基础

- **机器学习**：根据某些系统应有的行为，改善系统的性能
- **决策树模型**：根结点为起点，叶结点代表决策，根据样本数据绘制决策树，并根据输入数据和决策树确定输出
- **ID3算法**：自顶向下构造决策树
 - 当结点有多个子结点时，将样本数据按照子结点分类
 - 样本的特征几乎相同时，生成叶子结点
 - 框架：输入学习样本集，输出决策树
 - i. 生成根结点
 - ii. 若样例都为同类，则直接返回单结点树
 - iii. 求对样例分类能力最好的属性 A
 - iv. 对样例 $A = v_i (i = 1, 2, 3, \dots, n)$
 - 每个分支对应 $A = v_i$ 的结果
 - 将样本集按 $A = v_i$ 分类
 - 对上述步骤进行递归调用
- **熵模型**：定义熵为结果的不确定性
 - 类比条件概率，可以定义条件熵
 - 信息增益表示一个条件的确定对另一个条件的熵的减少作用
 - 条件熵与绝对熵的比值越小，信息增益越大，表示分类能力越强
 - 缺点：往往会偏向于离散程度更大、取值更多的属性，如时间
- **性能优化的方法**：
 - 随机森林：将多棵决策树合成为森林
 - 集成分类：使用多个原理差异很大的分类算法，并将分类算法的结果民主集中为最终结果
 - 分类器生成：每棵决策树生成时只选取部分样本和部分属性
 - 深度随机森林：融合随机森林而成的深度学习成果